

Système de Détection de Menaces basé sur l'Intelligence Artificielle

1. Introduction

Dans le contexte actuel de la cybersécurité, la détection automatique des menaces est devenue essentielle afin de protéger les systèmes informatiques contre des attaques de plus en plus sophistiquées. Ce projet a pour objectif de concevoir un système de détection de menaces basé sur l'intelligence artificielle, capable de classifier des activités comme étant bénignes ou malveillantes.

Ce travail s'inscrit dans le domaine de la classification supervisée et s'inspire également des concepts utilisés en biométrie, notamment à travers l'utilisation de métriques telles que le FAR (False Acceptance Rate) et le FRR (False Rejection Rate).

2. Description technique

2.1 Architecture du système

Le système développé suit les étapes suivantes :

1. Génération de données : Un dataset synthétique a été généré afin de simuler des comportements réseau et système, incluant des activités bénignes et malveillantes.
 2. Prétraitement : Les données sont normalisées à l'aide d'un StandardScaler afin d'assurer une meilleure convergence des modèles.
 3. Entraînement : Deux modèles de classification ont été entraînés :
 - Random Forest
 - Régression Logistique
 4. Prédiction : Le modèle sélectionné (Random Forest) est utilisé pour prédire si une activité est malveillante ou non.
 5. Évaluation : Le modèle est évalué à l'aide de plusieurs métriques (Accuracy, Precision, Recall, F1-score, FAR, FRR, EER).
 6. Simulation d'attaques : Des attaques artificielles sont appliquées au dataset pour tester la robustesse du modèle.
 7. Génération des rapports : Les résultats sont sauvegardés sous forme de graphiques et de fichiers JSON.
-

2.2 Algorithmes utilisés

- Random Forest : Un ensemble d'arbres de décision permettant une bonne robustesse face au bruit et aux données non linéaires.
 - Régression Logistique : Utilisée comme modèle de référence simple pour la classification binaire.
 - Seuil de décision : La classification repose sur un seuil de probabilité (par défaut 0.5).
 - FAR (False Acceptance Rate) : Proportion de données bénignes classées à tort comme malveillantes.
 - FRR (False Rejection Rate) : Proportion de données malveillantes classées à tort comme bénignes.
 - EER (Equal Error Rate) : Point où FAR et FRR sont égaux, indicateur clé en sécurité.
-

2.3 Justification des choix techniques

- Le Random Forest a été choisi pour sa robustesse et sa capacité à gérer des relations complexes.
 - La Régression Logistique permet d'avoir une baseline simple.
 - Le dataset synthétique a été utilisé faute d'accès à des logs réels pour des raisons de confidentialité.
 - Les métriques FAR, FRR et EER sont essentielles dans les systèmes de sécurité pour évaluer les erreurs critiques.
-

3. Analyse des performances

Les résultats obtenus sur les données de test montrent des performances élevées :

- Accuracy : 1.00
- Precision : 1.00
- Recall : 1.00
- F1-score : 1.00
- FAR : 0.00
- FRR : 0.00
- EER : 0.00

La matrice de confusion montre une séparation parfaite entre les classes dans les conditions normales.

Cependant, ces résultats doivent être interprétés avec prudence car ils sont obtenus sur des données synthétiques.

4. Simulations d'attaques

4.1 Attaque par bruit (Noise Attack)

Protocole : Ajout de bruit aléatoire aux caractéristiques.

Résultats : - Accuracy 0.89 - FAR 0.15 - FRR 0.01

Analyse : Le bruit dégrade fortement les performances en augmentant les faux positifs.

4.2 Attaque de spoofing

Protocole : Modification des données malveillantes pour les rendre similaires aux données bénignes.

Résultats : - Accuracy 0.99 - FRR 0.03

Analyse : Certaines attaques passent inaperçues, ce qui montre une faiblesse face au camouflage.

4.3 Attaque de compression

Protocole : Réduction de la précision des données (quantification).

Résultats : - Impact faible

Analyse : Le modèle est robuste face à la perte d'information légère.

4.4 Attaque adversariale

Protocole : Création d'échantillons proches de la frontière de décision.

Résultats : - Accuracy 0.91 - FAR 0.12

Analyse : Le modèle devient moins fiable lorsque les données sont ambiguës.

5. Discussion

Limites du système :

- Utilisation d'un dataset synthétique
- Absence de données réelles
- Modèle non déployé en environnement réel

- Pas de détection temps réel

Améliorations possibles :

- Utiliser des logs réels
 - Intégrer du deep learning
 - Ajouter un système de détection en temps réel
 - Améliorer la robustesse face aux attaques adversariales
-

6. Conclusion

Ce projet a permis de concevoir un système de détection de menaces basé sur l'intelligence artificielle. Les résultats montrent que le modèle est performant dans des conditions normales, mais qu'il peut être affecté par certaines attaques.

L'étude des métriques FAR, FRR et EER ainsi que des simulations d'attaques a permis de mieux comprendre les limites du système et d'ouvrir des perspectives d'amélioration.

Ce travail constitue une base solide pour le développement de systèmes de sécurité plus avancés. # Système de Détection de Menaces basé sur l'Intelligence Artificielle

1. Introduction

Dans le contexte actuel de la cybersécurité, la détection automatique des menaces est devenue essentielle afin de protéger les systèmes informatiques contre des attaques de plus en plus sophistiquées. Ce projet a pour objectif de concevoir un système de détection de menaces basé sur l'intelligence artificielle, capable de classifier des activités comme étant bénignes ou malveillantes.

Ce travail s'inscrit dans le domaine de la classification supervisée et s'inspire également des concepts utilisés en biométrie, notamment à travers l'utilisation de métriques telles que le FAR (False Acceptance Rate) et le FRR (False Rejection Rate).

2. Description technique

2.1 Architecture du système

Le système développé suit les étapes suivantes :

1. Génération de données : Un dataset synthétique a été généré afin de simuler des comportements réseau et système, incluant des activités bénignes et malveillantes.

2. Prétraitement : Les données sont normalisées à l'aide d'un StandardScaler afin d'assurer une meilleure convergence des modèles.
 3. Entraînement : Deux modèles de classification ont été entraînés :
 - Random Forest
 - Régression Logistique
 4. Prédiction : Le modèle sélectionné (Random Forest) est utilisé pour prédire si une activité est malveillante ou non.
 5. Évaluation : Le modèle est évalué à l'aide de plusieurs métriques (Accuracy, Precision, Recall, F1-score, FAR, FRR, EER).
 6. Simulation d'attaques : Des attaques artificielles sont appliquées au dataset pour tester la robustesse du modèle.
 7. Génération des rapports : Les résultats sont sauvegardés sous forme de graphiques et de fichiers JSON.
-

2.2 Algorithmes utilisés

- Random Forest : Un ensemble d'arbres de décision permettant une bonne robustesse face au bruit et aux données non linéaires.
 - Régression Logistique : Utilisée comme modèle de référence simple pour la classification binaire.
 - Seuil de décision : La classification repose sur un seuil de probabilité (par défaut 0.5).
 - FAR (False Acceptance Rate) : Proportion de données bénignes classées à tort comme malveillantes.
 - FRR (False Rejection Rate) : Proportion de données malveillantes classées à tort comme bénignes.
 - EER (Equal Error Rate) : Point où FAR et FRR sont égaux, indicateur clé en sécurité.
-

2.3 Justification des choix techniques

- Le Random Forest a été choisi pour sa robustesse et sa capacité à gérer des relations complexes.
- La Régression Logistique permet d'avoir une baseline simple.
- Le dataset synthétique a été utilisé faute d'accès à des logs réels pour des raisons de confidentialité.
- Les métriques FAR, FRR et EER sont essentielles dans les systèmes de sécurité pour évaluer les erreurs critiques.

3. Analyse des performances

Les résultats obtenus sur les données de test montrent des performances élevées :

- Accuracy : 1.00
- Precision : 1.00
- Recall : 1.00
- F1-score : 1.00
- FAR : 0.00
- FRR : 0.00
- EER : 0.00

La matrice de confusion montre une séparation parfaite entre les classes dans les conditions normales.

Cependant, ces résultats doivent être interprétés avec prudence car ils sont obtenus sur des données synthétiques.

4. Simulations d'attaques

4.1 Attaque par bruit (Noise Attack)

Protocole : Ajout de bruit aléatoire aux caractéristiques.

Résultats : - Accuracy 0.89 - FAR 0.15 - FRR 0.01

Analyse : Le bruit dégrade fortement les performances en augmentant les faux positifs.

4.2 Attaque de spoofing

Protocole : Modification des données malveillantes pour les rendre similaires aux données bénignes.

Résultats : - Accuracy 0.99 - FRR 0.03

Analyse : Certaines attaques passent inaperçues, ce qui montre une faiblesse face au camouflage.

4.3 Attaque de compression

Protocole : Réduction de la précision des données (quantification).

Résultats : - Impact faible

Analyse : Le modèle est robuste face à la perte d'information légère.

4.4 Attaque adversariale

Protocole : Création d'échantillons proches de la frontière de décision.

Résultats : - Accuracy 0.91 - FAR 0.12

Analyse : Le modèle devient moins fiable lorsque les données sont ambiguës.

5. Discussion

Limites du système :

- Utilisation d'un dataset synthétique
- Absence de données réelles
- Modèle non déployé en environnement réel
- Pas de détection temps réel

Améliorations possibles :

- Utiliser des logs réels
 - Intégrer du deep learning
 - Ajouter un système de détection en temps réel
 - Améliorer la robustesse face aux attaques adversariales
-

6. Conclusion

Ce projet a permis de concevoir un système de détection de menaces basé sur l'intelligence artificielle. Les résultats montrent que le modèle est performant dans des conditions normales, mais qu'il peut être affecté par certaines attaques.

L'étude des métriques FAR, FRR et EER ainsi que des simulations d'attaques a permis de mieux comprendre les limites du système et d'ouvrir des perspectives d'amélioration.

Ce travail constitue une base solide pour le développement de systèmes de sécurité plus avancés.